Centro Paula Souza

Fatec Jahu

CONCEITOS BÁSICOS SOBRE PLN

PROCESSAMENTO DE LINGUAGEM NATURAL

CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



CONCEITOS FUNDAMENTAIS DE PLN

CONCEITO	O QUE SIGNIFICA
Tokenização	Dividir texto em unidades menores
Lematização	Reduzir palavras à forma base
POS Tagging	Classificar palavras gramaticalmente
Parsing	Analisar estrutura sintática
NER	Identificar entidades
Stop Words	Remover palavras irrelevantes
Embeddings	Representação vetorial semântica

UM EXEMPLO PARA COMEÇAR

```python
import spacy

nlp = spacy.load("pt_core_news_sm")
texto = "O professor Tiago explicou PLN usando spaCy na Fatec."

doc = nlp(texto)

for token in doc:
    print(
        f"Texto: {token.text:10} | "
        f"Lemma: {token.lemma_:10} | "
        f"POS: {token.pos_:6} | "
        f"Stop: {token.is_stop}"
    )

print("\nEntidades:")
for ent in doc.ents:
    print(ent.text, ent.label_)
```

SAÍDA DO CÓDIGO EXEMPLO

```
Texto: O          | Lemma: o          | POS: DET    | Stop: True
Texto: professor  | Lemma: professor  | POS: NOUN   | Stop: False
Texto: Tiago      | Lemma: Tiago      | POS: PROPN  | Stop: False
Texto: explicou   | Lemma: explicar   | POS: VERB   | Stop: False
Texto: PLN        | Lemma: pLN        | POS: SCONJ  | Stop: False
Texto: usando     | Lemma: usar       | POS: VERB   | Stop: False
Texto: spaCy      | Lemma: spaCy      | POS: NOUN   | Stop: False
Texto: na         | Lemma: em o       | POS: ADP    | Stop: True
Texto: Fatec      | Lemma: Fatec      | POS: NOUN   | Stop: False
Texto: .          | Lemma: .          | POS: PUNCT  | Stop: False

Entidades:
Tiago PER
Fatec ORG
```

POR QUE VAMOS USAR A spaCy

- **spaCy** é excelente para:
  - Demonstrar conceitos teóricos de PLN com prática imediata
  - Mostrar pipeline de processamento real
  - Conectar teoria linguística com aplicações
  - Preparar **base para transformers** (ex: BERT)



PIPELINE DO OBJETO DA spaCy

- O objeto **doc** passa por um pipeline que pode conter:

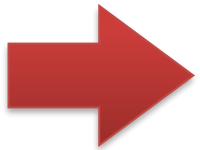
  1) Tokenizer
  2) Tagger (POS tagging)
  3) Parser (dependência sintática)
  4) NER (Reconhecimento de Entidades Nomeadas)
  5) Lemmatizer

```
 9  # Imprimindo os nomes dos componentes do pipeline
10  print(nlp.pipe_names)
```

TOKENIZAÇÃO

- É o primeiro passo, consiste em dividir uma frase em unidades menores, chamadas. Os **tokens** são palavras ou pontuações, mas também podem ser sub-palavras (comum em modelos modernos).
  - Exemplo: "*O gato correu.*" → `["O", "gato", "correu", "."]`

```
12  # Imprimindo os tokens do texto
13  for token in doc:
14      print(token.text)
```

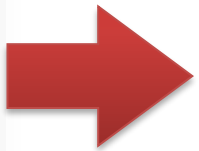


```
O
professor
Tiago
está
ensinando
PLN
na
Fatec
Jahu
.
```

LEMMA (LEMATIZAÇÃO)

- A forma canônica ou a base de cada palavra

```
16  # Imprimindo os lemas dos tokens
17  for token in doc:
18      print(token.text, "->", token.lemma_)
```



```
O -> o
professor -> professor
Tiago -> Tiago
está -> estar
ensinando -> ensinar
PLN -> PLN
na -> em o
Fatec -> Fatec
Jahu -> Jahu
. -> .
```

POS TAGGING (CLASSE GRAMATICAL)

- **Part-of-Speech (POS)** é o processo de rotular cada token de uma frase com sua classe gramatical (existem muitas).
- Existem diferentes conjuntos de etiquetas (tagsets):
  - Classes gramaticais da linguística tradicional
  - Tagset universal (Universal Dependencies – usado em pesquisas modernas)
  - Tagset Penn Treebank (muito usado em inglês e em bibliotecas clássicas)

```
20  # Imprimindo os tokens e suas classes gramaticais
21  for token in doc:
22      print(token.text, token.pos_)
```

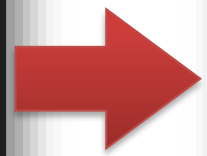
POS TAGGING (CLASSE GRAMATICAL)

TAG	NOME	EXEMPLO
ADJ	Adjetivo	bonito
ADP	Adposição (preposição/pós)	de
ADV	Advérbio	rapidamente
AUX	Verbo auxiliar	ter, ser
CCONJ	Conjunção coordenativa	e
DET	Determinante	o, um
INTJ	Interjeição	ah
NOUN	Substantivo comum	casa
NUM	Numeral	dois
PART	Partícula	não
PRON	Pronome	ele
PROPN	Substantivo próprio	Brasil
PUNCT	Pontuação	. , !
SCONJ	Conjunção subordinativa	porque
SYM	Símbolo	%
VERB	Verbo principal	correr
X	Desconhecido/outro	token estranho

STOP WORDS (PALAVRAS DE PARADA)

- São palavras que **ocorrem com muita frequência** mas carregam **pouco significado semântico** para certas análises (como "de", "a", "o", "com"). Muitas vezes, elas são removidas para reduzir o ruído nos dados.

```
16  # Imprimindo os tokens e se são stop words
17  for token in doc:
18      print(token.text, token.is_stop)
```

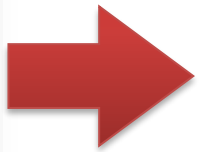


```
O True
professor False
Tiago False
está True
ensinando False
PLN False
na True
Fatec False
Jahu False
. False
```

DEPENDÊNCIA SINTÁTICA (DEPENDENCY PARSING)

- Identifica relações gramaticais entre palavras:

```
20  # Imprimindo as dpendências sintáticas dos tokens
21  for token in doc:
22      print(token.text, token.dep_, token.head.text)
```



```
O det professor
professor nsubj ensinando
Tiago nsubj ensinando
está aux ensinando
ensinando ROOT ensinando
PLN obj ensinando
na case Fatec
Fatec obl ensinando
Jahu flat:name Fatec
. punct ensinando
```

NAMED ENTITY RECOGNITION (NER)

- **Reconhecimento de Entidades Nomeadas** identifica:
  - Pessoas
  - Organizações
  - Localizações
  - Datas
  - Valores monetários

```
# Imprimindo as entidades nomeadas do texto
for ent in doc.ents:
    print(ent.text, ent.label_)
```

VETORES E SIMILARIDADE

- Alguns modelos do spaCy possuem **word embeddings**, que permitem medir similaridade semântica:
  - Sistemas de recomendação
  - Busca semântica
  - Agrupamento de textos



```
32  nlp = spacy.load("pt_core_news_lg")
33  doc1 = nlp("inteligência artificial")
34  doc2 = nlp("aprendizado de máquina")
35
36  print(doc1.similarity(doc2))
```

SENTENÇAS

- O spaCy também divide texto em sentenças:

```
40  # Imprimindo as sentenças do texto
41  doc = nlp("Eu gosto de IA. Ela transforma o mundo.")
42
43  for sent in doc.sents:
44      print(sent.text)
```

EXERCÍCIOS

Exercícios de fixação no Jupyter Notebook

EXERCÍCIO 1 – EXPLORANDO TOKENS

- Dado o texto:

  – "*A inteligência artificial está transformando a educação superior no Brasil.*"

- Faça um programa que:

  a) Mostre todos os tokens

  b) Mostre apenas tokens que são palavras (ignore pontuação)

  c) Conte o número total de tokens

EXERCÍCIO 2 – LEMATIZAÇÃO E NORMALIZAÇÃO

- Dado o texto:
  - "*Os alunos estavam estudando algoritmos e implementaram soluções eficientes.*"
- Faça um programa que:
  a) Mostre **`token.text`** e **`token.lemma_`**
  b) Gere uma lista contendo apenas os lemas
  c) Compare o texto original com o texto lematizado

EXERCÍCIO 3 – FILTRAGEM POR CLASSE GRAMATICAL

- Dado um texto qualquer a sua escolha, faça:
  a) Extraia apenas os verbos
  b) Extraia apenas os substantivos
  c) Conte quantos verbos existem no texto
- Use `token.pos_`
- **Desafio extra:**
  – Mostrar verbo + seu sujeito usando dependência sintática



EXERCÍCIO 4 – STOPWORDS E ESTATÍSTICAS

- Dado um parágrafo maior:
  - Remova stopwords
  - Remova pontuação
  - Gere uma lista de palavras "limpas"
  - Mostre as 5 palavras mais frequentes
- Objetivo:
  - Introduzir pré-processamento para Machine Learning



EXERCÍCIO 5 – FREQUÊNCIA DE PALAVRAS

- Crie um programa que:

a) Conte a frequência de cada palavra

b) Ordene da mais frequente para a menos frequente

c) Ignore:

  - Stopwords
  - Pontuação
  - Palavras com menos de 3 letras



EXERCÍCIO 6 – ENTIDADES NOMEADAS (NER)

- Dado o texto faça:
  - *"A OpenAI foi fundada em 2015 e possui escritórios em São Francisco."*

  a) Extraia todas as entidades

  b) Mostre texto da entidade + tipo (`ent.label_`)

  c) Conte quantas entidades de cada tipo existem
- Responda:
  - Como isso poderia ser usado em um sistema jurídico?
  - Ou em análise de notícias?

EXERCÍCIO 7 – MINI ANALISADOR DE NOTÍCIAS

- Busque uma noticia qualquer online e faça:
  - Extraia da notícia: Pessoas, organizações e Datas
  - Mostre um resumo estruturado: Pessoas Entradas, Organizações, Datas, etc.



EXERCÍCIO 8 – ANÁLISE SINTÁTICA

- Dado o texto:
  - "*O professor explicou aprendizado de máquina aos alunos.*"
- Faça um programa que:
  - Identifique o verbo principal
  - Identifique o sujeito
  - Identifique o objeto
- Use:
  - **`token.dep_`** e **`token.head`**
- **Desafio**: Testar com frases mais complexas



EXERCÍCIO 9 – SIMILARIDADE SEMÂNTICA

- **Compare**:
  - "inteligência artificial"
  - "aprendizado de máquina"
  - "futebol"
  - "redes neurais"
  - Calcule similaridade entre cada par
  - Mostre quais são semanticamente mais próximas
- **Responda**:
  - O modelo pequeno (sm) é confiável para similaridade?



OBRIGADO!

- Encontre este **material on-line** em:
  - Slides: **Google Classroom**

- Em caso de **dúvidas**, entre em contato:
  - **Prof. Me. Tiago**: tiago.silva@cps.sp.gov.br

