Centro Paula Souza

Fatec Jahu

BAG OF WORDS - BOW

PROCESSAMENTO DE LINGUAGEM NATURAL

CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



O QUE É BAG OF WORDS?

- O **Bag of Words** (Saco de Palavras) – **BoW** – é uma técnica de extração de características para documentos de texto.
- Imagine que você pega um parágrafo, **recorta cada palavra individualmente e as joga dentro de um saco**.
- Nesse processo, você perde a ordem das frases e a gramática, **mantendo apenas a frequência com que cada palavra aparece**.

COMO FUNCIONA O BANG OF WORDS?

- Para criar um modelo **BoW**, seguimos geralmente **estes passos**:
  - **Definição do Vocabulário**: O modelo lista todas as palavras únicas que aparecem em um conjunto de textos (o "***corpus***").
  - **Vetorização**: Cada frase ou documento é transformado em um vetor (uma lista de números). O tamanho desse vetor é igual ao tamanho do seu vocabulário total.
  - **Contagem**: Para cada frase, você marca quantas vezes cada palavra do vocabulário apareceu ali.

EXEMPLO BANG OF WORDS

- Imagine 3 frases:
  - "*gosto de machine learning*"
  - "*machine learning é incrível*"
  - "*gosto de programar*“
- Ficando o vocabulário:
  - **[gosto, de, machine, learning, é, incrível, programar]**

EXEMPLO BAG OF WORDS

	gosto	de	machine	learning	é	incrível	programar
Doc1	1	1	1	1	0	0	0
Doc2	0	0	1	1	1	1	0
Doc3	1	1	0	0	0	0	1

PÓS E CONTRAS

- **Vantagens**:
  - **Simplicidade**: É muito fácil de entender e implementar.
  - **Eficiência**: Funciona muito bem para tarefas simples, como classificação de **spam** ou análise de sentimentos básica, onde a presença de certas palavras (como "promoção" ou "ganhou") já indica muito sobre o conteúdo.



PÓS E CONTRAS

- **Desvantagens**:
  - **Perda de Contexto**: Como a ordem não importa, as frases "**O cão mordeu o homem**" e "**O homem mordeu o cão**" teriam vetores idênticos, apesar de significados bem diferentes.
  - **Sparsity (Esparsidade):** Se você tiver um vocabulário de 10.000 palavras e uma frase de 5 palavras, o seu vetor terá 9.995 zeros. Isso gasta muita memória computacional.
  - **Palavras Irrelevantes**: Palavras como "o", "a", "de" (**stop words**) aparecem muito e podem "poluir" o modelo se não forem filtradas.

IMPLEMENTANDO BAG OF WORDS

```python
from sklearn.feature_extraction.text import CountVectorizer

corpus = [
    "gosto de machine learning",
    "machine learning é incrível",
    "gosto de programar"
]

vectorizer = CountVectorizer()
X = vectorizer.fit_transform(corpus)

print("Vocabulário:")
print(vectorizer.get_feature_names_out())

print("\nMatriz:")
print(X.toarray())
```



IMPLEMENTANDO BAG OF WORDS

- Saída do código:

```
Vocabulário:
['de' 'gosto' 'incrível' 'learning' 'machine' 'programar']

Matriz:
[[1 1 0 1 1 0]
 [0 0 1 1 1 0]
 [1 1 0 0 0 1]]
```



UM CLASSIFICADOR DE FEEDBACKS

- Vamos implementar no Jupyter Notebook...







EXERCÍCIOS

Exercícios de fixação no Jupyter Notebook

EXERCÍCIO 1 – FILTRO DE SPAM MANUAL (O CLÁSSICO)

- Crie um conjunto de dados pequeno (10 frases) de mensagens de SMS. Metade deve ser "Spam" (ex: "Ganhe prêmio agora", "Clique no link") e metade "Ham/Comum" (ex: "Oi, tudo bem?", "Vamos almoçar?").
  - Tarefa: Use o **`CountVectorizer`** para transformar as mensagens em vetores. Identifique quais são as 5 palavras que possuem a maior contagem no grupo de Spam e veja se elas fazem sentido intuitivo.
  - Dica: Tente classificar uma mensagem nova apenas comparando se ela tem mais palavras do "vocabulário spam" ou do "comum".

EXERCÍCIO 2 – O PROBLEMA DA NEGAÇÃO (CONTEXTO)

- O Desafio: Compare estas duas frases:
  - "Eu gosto deste filme, não é ruim."
  - "Eu não gosto deste filme, é ruim."
- Tarefa: Gere os vetores BoW para ambas. Você notará que os vetores são idênticos (ambas têm as mesmas palavras).
- Solução: Refaça o exercício usando o parâmetro ngram_range=(1, 2) no CountVectorizer. Observe como o vocabulário agora inclui "não gosto" e "não é", diferenciando as frases.

EXERCÍCIO 3 – LIMPEZA DE DADOS (STOP WORDS)

- O Desafio: Pegue um texto longo (pode ser uma notícia ou um artigo).
- Tarefa: Gere o Bag of Words e liste as 10 palavras mais frequentes. Provavelmente serão "o", "a", "de", "em" (stop words).
- Evolução: Aplique uma lista de stop words em português e compare o tamanho do vetor antes e depois. Veja como o vocabulário "limpo" foca em substantivos e verbos que carregam o significado real do texto.

EXERCÍCIO 4 – IMPLEMENTAÇÃO "FROM SCRATCH"

- O Desafio: Implementar o Bag of Words **sem usar o scikit-learn**.
- Tarefa: 1. Crie uma função que receba uma lista de frases.
  - 2. Quebre as frases em palavras (tokenização).
  - 3. Crie um dicionário único de palavras (vocabulário).
  - 4. Retorne uma lista de listas (matriz) com as contagens.
- Por que fazer? Isso ajuda a entender como lidar com pontuações e letras maiúsculas/minúsculas, algo que o CountVectorizer já faz automaticamente, mas que é vital conhecer.

OBRIGADO!

- Encontre este **material on-line** em:
  - Slides: **Google Classroom**

- Em caso de **dúvidas**, entre em contato:
  - **Prof. Me. Tiago**: tiago.silva@cps.sp.gov.br

